## Policy Gradient

이다경



## 1. Policy-based Reinforcement Learning

## 2. Policy Objective Function

- Finite different policy gradient
- Monte-Carlo policy gradient
- Actor-Critic policy gradient

## Value-based vs Policy-based

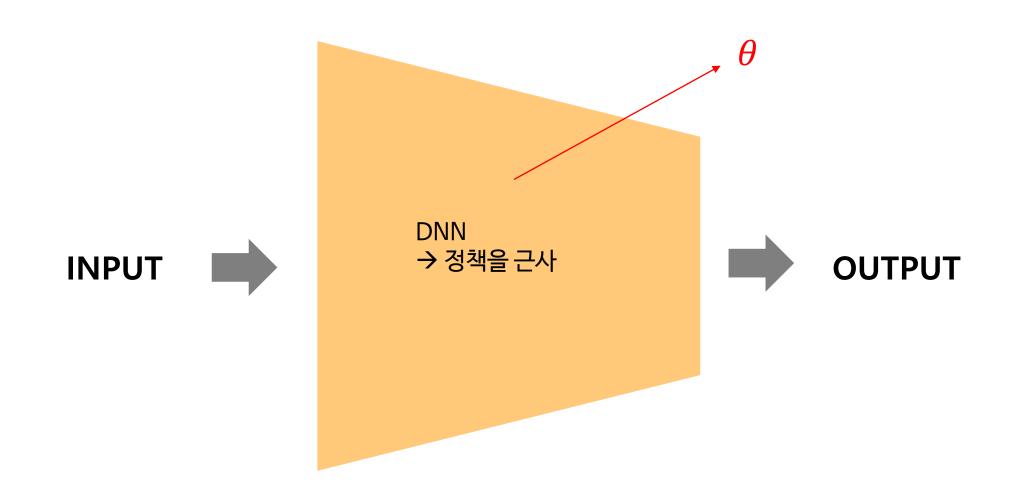
#### Value-based

Q라는 action-value function에 초점을 맞추어 Q function을 구하고 이것을 토대로 policy를 구하는 방법

ex) DQN : DNN을 이용하여 Q-function을 approximate 하고 이를 통해 policy를 구하는 방법

## Policy-based

Policy 자체를 approximate 즉, DNN에서 나오는 것이 value가 아닌 policy자체!



정책 
$$\pi_{\theta}(a|s) = P[A_t = a|S_t = s, \theta]$$

## Policy-based 장단점

## 장점

#### 1. 수렴

value-based에서는 value를 바탕으로 policy를 계산하기 때문에, value가 조금만 달라져도 policy가 크게 변화
→ 수렴에 불안정

But policy-based에서는 policy자체가 함수화 되어 학습하면서 조금씩 변화하기 때문에 안정적이고 부드럽게 수렴

#### 2. Stochastic한 policy정책

→ "가위바위보" (가위, 바위, 보를 1/3씩 내는 것이optimal) 처럼 stochastic한 policy 배울 수 있음

#### 단점

- 1. Local optimum에 빠질 수도
- 2. Variance가 높음

Q function이 output으로 나오는 DNN이 아니라 Policy가 output으로 나오는 DNN을 만들 것! DNN을 update할 기준이 DQN에서는 target과 현재 Q function 값의 차이였다면, Policy Gradient에서는 Objective Function(= $J(\theta)$ ) 정의

Policy Gradient에서 목표는 Objective Function을 최대화 시키는 theta (policy의 parameter vector)을 찾 아내는 것.

→ 그 방법이 gradient descent

Objective Function의 gradient를 구하는 세 가지 방법

- 1. Finite different policy gradient
- 2. Monte-Carlo policy gradient
- 3. Actor-Critic policy gradient

에이전트가 정책  $\pi_{\theta}$  에 따라서 가게 되는 "경로"를 생각해보자!

경로(trajectory) = 에이전트와 환경이 상호작용한 흔적

$$\tau = s_0, a_0, r_1, s_1, a_1, r_2, \dots, s_T$$

 $J(\theta)$  = 경로 동안 받을 것이라고 기대하는 보상의 합(경로가 매번 달라지므로)

$$J(\theta) = \mathbf{E} \left[ \sum_{t=0}^{T-1} r_{t+1} \mid \pi_{\theta} \right] = \mathbf{E} [r_1 + r_2 + r_3 + \dots + r_T \mid \pi_{\theta}]$$

 $J(\theta)$ 를 기준으로  $\theta$ (정책신경망)을 어떻게 업데이트할 것인가?

 $\rightarrow \theta$ 에 대한  $J(\theta)$ 의 경사를 따라 올라가다 (Gradient Ascent)

$$\theta' = \theta + \alpha \nabla_{\theta} J(\theta)$$

$$\nabla_{\theta} J(\theta)$$
 = Policy Gradient

1. Finite Difference Policy Gradient

- For each dimension  $k \in [1, n]$ 
  - $\blacksquare$  Estimate kth partial derivative of objective function w.r.t.  $\theta$
  - $\blacksquare$  By perturbing  $\theta$  by small amount  $\epsilon$  in kth dimension

$$\frac{\partial J(\theta)}{\partial \theta_k} \approx \frac{J(\theta + \epsilon u_k) - J(\theta)}{\epsilon}$$

- Numerical Method
- 간단하지만, 비효율적인 방법
- But Policy가 미분 가능하지 않더라도 작동

$$\nabla_{\theta} J(\theta) \sim \sum_{t=0}^{T-1} \nabla_{\theta} log \pi_{\theta}(a_t | s_t) G_t$$

$$\nabla_{\theta} J(\theta) \sim \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t|s_t) G_t$$

$$\tau = s_0, a_0, r_1, s_1, a_1, r_2, \dots, s_T$$

$$J(\theta) = E\left[\sum_{t=0}^{T-1} r_{t+1} | \pi_{\theta}\right] = E_{\tau}[r_1 | \pi_{\theta}] + E_{\tau}[r_2 | \pi_{\theta}] + E_{\tau}[r_3 | \pi_{\theta}] + \cdots$$

$$= \sum_{t=0}^{T-1} P(s_t, a_t | \tau) r_{t+1}$$

$$= \sum_{t=0}^{T-1} P(s_t, a_t | \tau) r_{t+1}$$

$$(s_t, a_t)$$
일 확률  $(s_t, a_t)$ 일 때의 값
$$E[f(x)] = \sum_{x} p(x) f(x)$$

2. Monte-Carlo Policy Gradient

# $\nabla_{\theta} J(\theta) \sim \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t$

양변에 미분 취하기

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} E \left[ \sum_{t=0}^{T-1} r_{t+1} | \pi_{\boldsymbol{\theta}} \right]$$

$$= \nabla_{\boldsymbol{\theta}} \sum_{t=0}^{T-1} P(s_t, a_t | \tau) r_{t+1}$$

$$= \sum_{t=0}^{T-1} \nabla_{\boldsymbol{\theta}} P(s_t, a_t | \tau) r_{t+1} = \sum_{t=0}^{T-1} P(s_t, a_t | \tau) \frac{\nabla_{\boldsymbol{\theta}} P(s_t, a_t | \tau)}{P(s_t, a_t | \tau)} r_{t+1}$$

$$= \sum_{t=0}^{T-1} P(s_t, a_t | \tau) \nabla_{\boldsymbol{\theta}} log P(s_t, a_t | \tau) r_{t+1}$$

$$\frac{dlogx}{dx} = \frac{1}{x}$$

$$\frac{dlogf(x)}{dx} = \frac{df(x)/dx}{f(x)}$$

$$\sum_{t=0}^{T-1} P(s_t, a_t | \tau) \nabla_{\theta} log P(s_t, a_t | \tau) r_{t+1}$$

$$= E_{\tau} \left[ \sum_{t=0}^{T-1} \nabla_{\theta} log P(s_t, a_t | \tau) r_{t+1} \right]$$

$$E[f(x)] = \sum_{x} p(x)f(x)$$

$$\nabla_{\theta} J(\theta) \sim \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t|s_t) G_t$$

$$\begin{split} P(s_t, a_t | \tau) &= \mathsf{P}(s_0, a_0, r_1, s_1, a_1, r_2, \dots, s_t, a_t | \theta) \\ &= \mathsf{P}(s_0) \pi_{\theta}(a_0 | s_0) \mathsf{P}(s_1 | s_0, a_0) \pi_{\theta}(a_1 | s_1) \mathsf{P}(s_2 | s_1, a_1) \dots \end{split}$$

$$\begin{split} &log P(s_t, a_t | \tau) \\ &= \log[P(s_0) \pi_{\theta}(a_0 | s_0) P(s_1 | s_0, a_0) \pi_{\theta}(a_1 | s_1) \dots \\ &+ P(s_t | s_{t-1}, a_{t-1}) \pi_{\theta}(a_t | s_t)] \\ &= \log P(s_0) + \log \pi_{\theta}(a_0 | s_0) + \log P(s_1 | s_0, a_0) + \log \pi_{\theta}(a_1 | s_1) \dots \\ &+ \log P(s_t | s_{t-1}, a_{t-1}) + \log \pi_{\theta}(a_t | s_t) \end{split}$$

$$\nabla_{\theta} log P(s_t, a_t | \tau)$$

$$= \nabla_{\theta}[\log P(s_0) + \log \pi_{\theta}(a_0|s_0) + \log P(s_1|s_0, a_0) + \log \pi_{\theta}(a_1|s_1) \dots \\ + \log P(s_t|s_{t-1}, a_{t-1}) + \log \pi_{\theta}(a_t|s_t)]$$

$$= \nabla_{\theta} \log \pi_{\theta}(a_0|s_0) + \nabla_{\theta} \log \pi_{\theta}(a_1|s_1) + \dots + \nabla_{\theta} \log \pi_{\theta}(a_t|s_t)$$

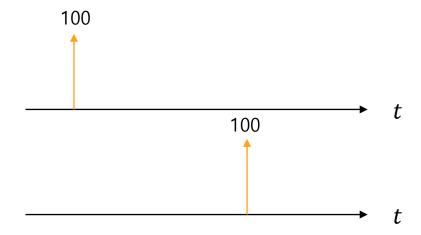
$$\begin{split} &\sum_{t=0}^{T-1} \nabla_{\theta} log P(s_t, a_t | \tau) r_{t+1} \\ &= \sum_{t=0}^{T-1} r_{t+1} [\nabla_{\theta} log \pi_{\theta}(a_0 | s_0) + \nabla_{\theta} log \pi_{\theta}(a_1 | s_1) + \dots + \nabla_{\theta} log \pi_{\theta}(a_t | s_t)] \\ &= \sum_{t=0}^{T-1} r_{t+1} (\sum_{t=0}^{T-1} \nabla_{\theta} log \pi_{\theta}(a_{t'} | s_{t'})) &= \sum_{t=0}^{T-1} \nabla_{\theta} log \pi_{\theta}(a_t | s_t) \sum_{t'=t+1}^{T} r_{t'} \end{split}$$

$$\nabla_{\theta} J(\theta) \sim \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t|s_t) G_t$$

2. Monte-Carlo Policy Gradient

$$\nabla_{\boldsymbol{\theta}} \boldsymbol{J}(\boldsymbol{\theta}) = E_{\tau} \left[ \sum_{t=0}^{T-1} \nabla_{\boldsymbol{\theta}} \log \pi_{\boldsymbol{\theta}}(a_t | s_t) \sum_{t'=t+1}^{T} r_{t'} \right]$$

이때, 
$$\sum_{t'=t+1}^{T} r_{t'}$$
 와 같은 단순 보상의 합  $\rightarrow$  문제!



$$\nabla_{\theta} J(\theta) \sim \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t|s_t) G_t$$

감가율(discount factor)  $0 \le \gamma \le 1$  도입

$$\nabla_{\theta} J(\theta) = E_{\tau} \left[ \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \sum_{t'=t+1}^{T} r_{t'} \right]$$

$$\sim E_{\tau} \left[ \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \sum_{t'=t+1}^{T} \gamma^{t'-t-1} r_{t'} \right]$$

$$\sum\nolimits_{t'=t+1}^{T} \gamma^{t'-t-1} r_{t'} = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots + \gamma^{T-t-1} r_{T'} \rightarrow G_t$$

$$\nabla_{\theta} J(\theta) \sim \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t|s_t) G_t$$

2. Monte-Carlo Policy Gradient

$$\nabla_{\theta} J(\theta) = \mathbf{E}_{\tau} \left[ \sum_{t=0}^{T-1} \nabla_{\theta} log \pi_{\theta}(a_t | s_t) G_t \right]$$

강화학습에서는 E[]를 계산 하지 않고 Sampling

$$\nabla_{\theta} J(\theta) \sim \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t$$

$$\theta \leftarrow \theta + \alpha \nabla_{\theta} J(\theta) = \theta + \alpha \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t$$

2. Monte-Carlo Policy Gradient

- 1. 한 에피소드를 현재 정책에 따라 실행
- 2. Trajectory를 기록
- 3. 에피소드가 끝난 뒤  $G_t$  계산
- 4. Policy gradient를 계산하여 정책 업데이트
- 4. Folicy gradiente 게근이어 6~ B데이트

\* Policy gradient = 
$$\sum_{t=0}^{T-1} \nabla_{\theta} log \pi_{\theta}(a_t|s_t) G_t$$

5. (1~4) 반복

에피소드 마다 업데이트 → Monte-Carlo Policy gradient

```
function REINFORCE
Initialize \theta arbitrarily
for each episode \{s_0, a_0, r_1, s_1, a_1, r_2, \dots, s_T\} \sim \pi_{\theta} do
for t = 1 too T-1 do
\theta \leftarrow \theta + \alpha \nabla_{\theta} \log \pi_{\theta}(a_t|s_t) G_t
end for
end for
return \theta
end function
```

3. Actor-Critic Policy Gradient

Monte-Carlo Policy gradient는 한 에피소드가 끝나야지만 업데이트!

- → Actor-Critic Policy Gradient는 time-step마다 업데이트 하는 방법
- → DNN을 두 개 만들어서 Policy뿐 아니라 Q function도 approximate해서 gradient를 구하자!

Actor는 Policy를, Critic은 Q-function을 approximate

3. Actor-Critic Policy Gradient

$$\tau = s_0, a_0, r_1, s_1, a_1, r_2, \dots, s_T$$

$$\nabla_{\theta} J(\theta) = \mathbf{E}_{\tau} \left[ \sum_{t=0}^{T-1} \nabla_{\theta} log \pi_{\theta}(a_t | s_t) G_t \right]$$

Expectation을 쪼개자 
$$\rightarrow$$
  $(s_0 \sim a_t) + (r_{t+1} \sim r_T)$ 

$$\sum_{t=0}^{T-1} E_{s_0,a_0,\dots,s_t,a_t} [\nabla_{\theta} \log \pi_{\theta}(a_t|s_t)] E_{r_{t+1},s_{t+1},\dots,s_T,r_T} [G_t]$$

$$Q$$
-function  $Q_{\pi \theta}(s_t, a_t)$ 

3. Actor-Critic Policy Gradient

$$\nabla_{\theta} J(\theta) = E_{\tau} \left[ \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) Q_{\pi\theta}(s_t, a_t) \right]$$

$$\sim \sum_{t=0}^{I-1} \nabla_{\theta} \log \pi_{\theta}(a_t|s_t) Q_{\pi\theta}(s_t, a_t)$$

알 수 있다면, 매 time-step마다 업데이트 가능!

$$Q_{\pi\theta}(s_t, a_t) \approx Q_{W}(s_t, a_t)$$

Q-function approximate한 DNN으로

$$\sim \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t|s_t) Q_{W}(s_t, a_t)$$

3. Actor-Critic Policy Gradient - Baseline

State value function을 일종의 평균으로 사용해서 현재의 행동이 평균적으로 얻을 수 있는 value보다 얼마나 더 좋은 것인가를 계산 → variance문제 해결

$$\nabla_{\boldsymbol{\theta}} \boldsymbol{J}(\boldsymbol{\theta}) \sim \log \pi_{\boldsymbol{\theta}}(a_t|s_t) Q_{\boldsymbol{W}}(s_t, a_t)$$

$$\nabla_{\boldsymbol{\theta}} \boldsymbol{J}(\boldsymbol{\theta}) \sim \log \pi_{\boldsymbol{\theta}}(a_t|s_t) (Q_{\boldsymbol{W}}(s_t,a_t) - V_{\boldsymbol{v}}(s_t))$$

원래는 왼쪽 1, 오른쪽 2 → 왼쪽 -1, 오른쪽 1

3. Actor-Critic Policy Gradient - Baseline

이미 사용하고 있는 DNN이 2개! 따라서 V까지 DNN하면 너무 비효율적

$$Q(s_t, a_t) = E[r_{t+1} + \gamma V(s_{t+1}) | s_t, a_t]$$
 이용

$$\nabla_{\boldsymbol{\theta}} \boldsymbol{J}(\boldsymbol{\theta}) \sim \nabla_{\boldsymbol{\theta}} \log \pi_{\boldsymbol{\theta}}(a_t|s_t) (r_{t+1} + \gamma V(s_{t+1}) - V_v(s_t))$$
 큐함수 배이스라인

3. Actor-Critic Policy Gradient - Baseline

#### 1. Actor

- 정책을 근사 : *θ*
- $\nabla_{\theta} \log \pi_{\theta}(a_t|s_t)(r_{t+1} + \gamma V(s_{t+1}) V_v(s_t))$ 로 업데이트

#### 2. Critic

- 가치함수(Value function)을 근사 : v
- $(r_{t+1} + \gamma V(s_{t+1}) V_v(s_t))^2$  의 오차함수로 업데이트

#### Actor의 loss function

$$\nabla_{\boldsymbol{\theta}} \log \pi_{\boldsymbol{\theta}}(a_t|s_t)(r_{t+1} + \gamma V(s_{t+1}) - V_v(s_t))$$

크로스 엔트로피

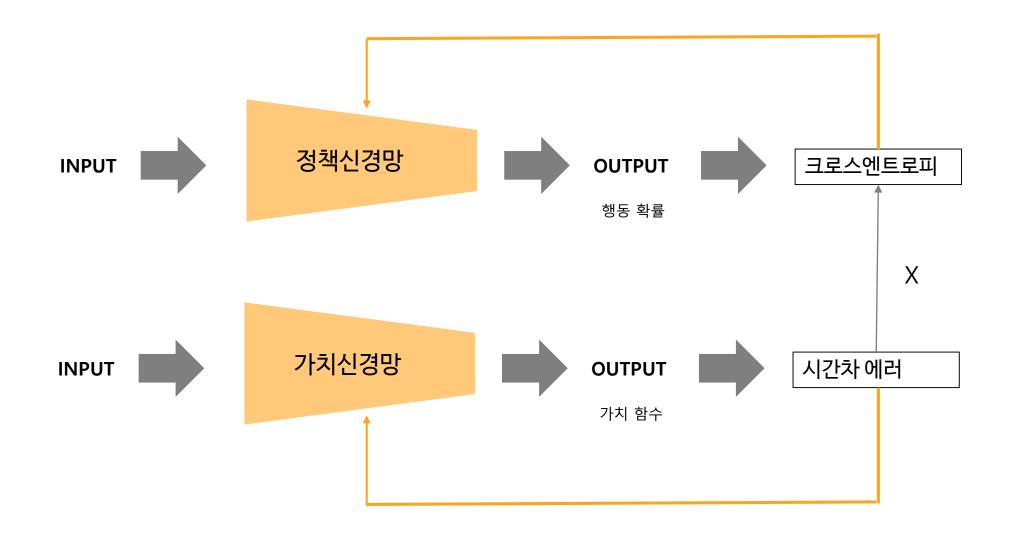
시간차 에러

#### Critic의 loss function

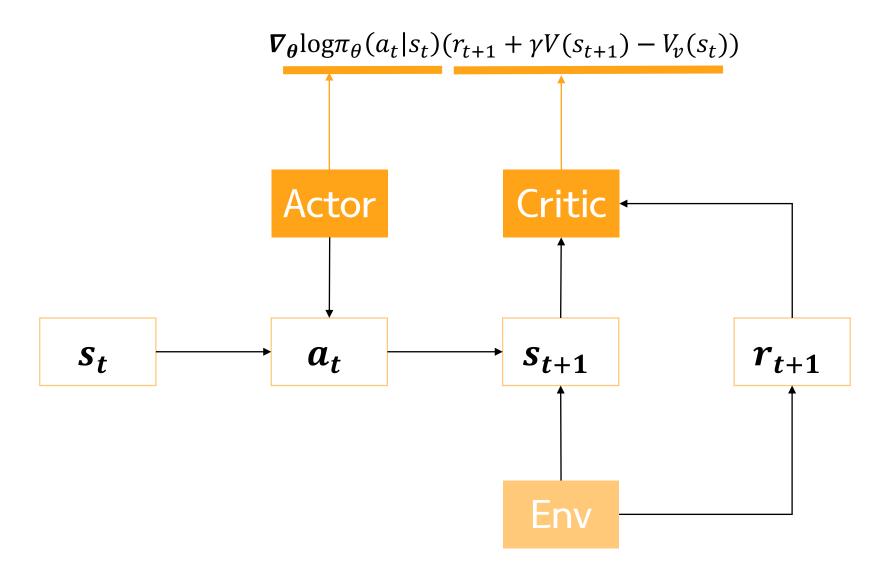
$$(r_{t+1} + \gamma V(s_{t+1}) - V_v(s_t))^2$$

시간차 에러

## Policy Objective Function 3. Actor-Critic Policy Gradient - Baseline



3. Actor-Critic Policy Gradient - Baseline



https://www.youtube.com/watch?v=gINks-YCTBs http://www.modulabs.co.kr/RL\_library/3305

https://github.com/dennybritz/reinforcement-learning/tree/master/PolicyGradient